

Trabalho Final da Disciplina de Probabilidade e Estatística
Curso de Engenharia da Computação

Instituto Federal de Educação, Ciência e Tecnologia do Ceará (IFCE)

Professor: Valberto Feitosa

1. Objetivo

Ao final da atividade, os alunos deverão ser capazes de desenvolver uma solução completa de Machine Learning, abrangendo desde a análise da base de dados até a disponibilização de um modelo treinado em uma aplicação web.

Para isso, deverão:

1. Utilizar a base de dados **Breast Cancer Wisconsin Diagnostic Dataset**, disponibilizada pelo professor.
 2. Analisar e compreender as características da base de dados.
 3. Selecionar e justificar as variáveis (features) utilizadas no treinamento.
 4. Treinar um modelo de Machine Learning utilizando o algoritmo **Naive Bayes**.
 5. Salvar o modelo treinado para utilização posterior.
 6. Desenvolver uma aplicação web simples (front-end e back-end) que permita ao usuário inserir dados e obter previsões utilizando o modelo treinado.
-

2. Desenvolvimento da Atividade

2.1 Análise da Base de Dados

Todos os grupos deverão utilizar a base de dados **Breast Cancer Wisconsin Diagnostic Dataset**.

A base possui:

- 569 observações;
- 30 variáveis preditoras;
- 1 variável-alvo (diagnóstico);
- duas classes:
 - Benigno;
 - Maligno.

Cada equipe deverá:

1. Realizar uma análise exploratória dos dados;
 2. Apresentar estatísticas descritivas das variáveis;
 3. Investigar a distribuição das classes;
 4. Justificar a escolha das variáveis utilizadas no modelo;
 5. Explicar eventuais etapas de pré-processamento adotadas.
-

2.2 Treinamento do Modelo com Naive Bayes

Os alunos deverão utilizar Python e bibliotecas apropriadas, como o Scikit-Learn, para realizar as seguintes etapas:

1. Carregar a base de dados;
2. Selecionar as variáveis preditoras;
3. Dividir os dados em conjuntos de treinamento e teste;
4. Treinar um modelo Naive Bayes utilizando o conjunto de treinamento;
5. Avaliar o desempenho do modelo.

A avaliação deverá apresentar, no mínimo:

- Acurácia;
- Precisão (Precision);
- Revocação (Recall);
- F1-Score;
- Matriz de Confusão.

Salvamento do Modelo Treinado

Após o treinamento, o modelo deverá ser salvo utilizando:

- joblib; ou
- pickle.

O arquivo salvo deverá ser utilizado posteriormente pela aplicação web.

2.3 Desenvolvimento da Aplicação Web

Os alunos deverão desenvolver uma aplicação web simples que permita a interação do usuário com o modelo treinado.

2.3.1 Front-End

O front-end deverá:

- possuir uma página HTML;
- conter um formulário para entrada dos dados;
- apresentar campos correspondentes às variáveis utilizadas no treinamento;
- possuir um botão "Prever".

A criatividade na construção da interface será considerada na avaliação.

2.3.2 Back-End

O back-end deverá ser desenvolvido utilizando Flask, Django ou framework equivalente.

O sistema deverá:

- carregar o modelo salvo;
 - receber os dados enviados pelo formulário;
 - aplicar o modelo Naive Bayes;
 - retornar o resultado ao usuário.
-

2.3.3 Exibição do Resultado

A aplicação deverá exibir claramente a classe prevista:

- Tumor Benigno; ou
- Tumor Maligno.

Opcionalmente, a equipe poderá apresentar também a probabilidade associada à previsão.

3. Ferramentas e Tecnologias

- Python
 - Scikit-Learn
 - Pandas
 - NumPy
 - Joblib ou Pickle
 - Flask ou Django
 - HTML
 - CSS
 - JavaScript
-

4. Fluxo da Aplicação

1. O usuário acessa a aplicação.
 2. Preenche os campos do formulário.
 3. Clica no botão "Prever".
 4. O back-end processa os dados.
 5. O modelo realiza a previsão.
 6. O resultado é exibido ao usuário.
-

5. Critérios de Avaliação

A nota do trabalho terá valor máximo de **5,0 pontos** e será composta por duas partes:

5.1 Nota da Equipe (4,0 pontos)

Esta nota será atribuída igualmente a todos os integrantes da equipe, considerando a qualidade técnica do projeto desenvolvido.

Critério	Pontuação
Análise exploratória da base de dados	0,5
Seleção e justificativa das features	0,5
Treinamento e avaliação do modelo	1,0
Desenvolvimento do Back-End	0,75
Desenvolvimento do Front-End	0,75
Documentação do projeto	0,5
Total	4,0

5.2 Nota Individual (1,0 ponto)

A nota individual será atribuída pelo professor durante a apresentação do trabalho, considerando:

Critério	Pontuação
Domínio do conteúdo apresentado	0,4
Participação efetiva no desenvolvimento do projeto	0,3
Clareza e segurança na apresentação	0,3
Total	1,0

Nota Final

Nota Final = Nota da Equipe + Nota Individual

Valor máximo: **5,0 pontos**

Observações

- Todos os integrantes deverão participar da apresentação.
- O professor poderá realizar perguntas individuais sobre qualquer parte do projeto.
- Alunos que demonstrarem desconhecimento do trabalho poderão ter redução na nota individual.
- A ausência na apresentação implicará atribuição de nota zero na parte individual, salvo justificativa aceita pelo professor.
- Todas as equipes deverão utilizar a base de dados Breast Cancer Wisconsin Diagnostic Dataset disponibilizada pelo professor.

6. Considerações Finais

Este trabalho permitirá aos alunos:

- aplicar o algoritmo Naive Bayes em um problema real de classificação;
- compreender o ciclo completo de um projeto de Machine Learning;
- desenvolver habilidades práticas em desenvolvimento web;
- integrar modelos de Machine Learning a aplicações interativas.

Observação: Todas as equipes utilizarão a mesma base de dados, permitindo a comparação dos resultados obtidos e das estratégias adotadas para seleção de atributos, treinamento do modelo e desenvolvimento da aplicação.

Base de Dados Utilizada

Breast Cancer Wisconsin Diagnostic Dataset (WDBC)

Documentação oficial da base de dados:

<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>

A base contém 569 observações, 30 variáveis preditoras e uma variável-alvo referente ao diagnóstico do tumor (Benigno ou Maligno). Não possui valores faltantes e é amplamente utilizada em estudos e aplicações de Machine Learning.